

INF05010 Otimização Combinatória  
**Algoritmo de Simulated Annealing para o Problema das Viagens de Avião**

Ernesto Vaz de Oliveira e Ricco Vasconcellos Constante Soares

### 1. Introdução

O objetivo do presente trabalho foi implementar a meta-heurística de Simulated Annealing para resolver o problema das Viagens de Avião.

O problema das Viagens de Avião pode ser descrito da seguinte maneira: dados  $k$  aviões e  $n$  pessoas, conhecendo a capacidade  $P$  máxima de cada avião, o preço  $c_i$ ,  $i \in [n]$  que cada pessoa está disposta a pagar pela passagem, além de um preço adicional  $C_{ij}$ ,  $i \in [n]$ ,  $j \in [n]$  para cada outra pessoa caso elas sejam alocadas no mesmo avião, deseja-se obter a configuração das pessoas alocadas em aviões que maximiza o lucro

### 2. Formulação do Programa Inteiro

Uma solução de VA será representada por uma matriz  $V_{ij}$ , com  $i \in [k]$  e  $j \in [n]$ , possuindo valor um se pessoa  $j$  estará em avião  $i$ , caso contrário valor será zero.

Função Objetivo:

$$\text{Maximiza: } \sum_{i=1}^k \left( \sum_{j=1}^n (c_j \times V_{ij} + \sum_{o=1}^n c_{oj} \times V_{io} \times V_{ij}) \right)$$

Sujeito a:

$$\sum_{i=1}^k V_{ij} \leq 1, \forall j \in [n] \quad (1)$$

$$\sum_{j=1}^n p_j \times V_{ij} \leq P_i, \forall i \in [k] \quad (2)$$

$$V_{ij} \in \{0, 1\}, \forall j \in [n], \forall i \in [k] \quad (3)$$

- (1) Nenhuma pessoa irá viajar em mais de 1 avião.
- (2) Somatório dos pesos das pessoas não excede capacidade do avião.
- (3) A matriz de solução só assume valores booleanos.

### 3. Simulated annealing como meta-heurística

A solução abordada foi a de utilizar como meta-heurística o algoritmo de simulated annealing, que, através de uma analogia com o recozimento na metalurgia, fundamenta um

processo de busca local no espaço do problema que diminui sua probabilidade de aceitar soluções piores ao longo do tempo. Com isso, buscou-se estabelecer uma vizinhança para soluções do problema e realizar uma busca local por máximos usando o algoritmo de simulated annealing.

#### 4. Parâmetros

Além de uma instância do problema, o algoritmo de simulated annealing como meta-heurística recebe uma série de parâmetros: taxa de decaimento  $r$ , número de iterações em temperatura constante  $I$ , temperatura inicial  $T_i$  e um valor  $k$  de iterações para o algoritmo de Metropolis. Outro possível parâmetro seria a função de probabilidade de aceitação. Contudo, será adotada a escolha convencional de usar a distribuição de Boltzmann para essa probabilidade.

Para a **temperatura inicial**, foram geradas soluções aleatórias (inserindo o maior número de pessoas possível em cada avião de forma aleatória) e a temperatura inicial é igual ao valor da função objetivo da pior solução aleatória, subtraído da melhor. Isso foi feito de forma a gerar temperatura com grandeza próxima à magnitude da função objetivo.

O **número de iterações sem alterar temperatura** (parâmetro  $I$ ) deve ter magnitude próxima à da vizinhança do problema, portanto foi tomado  $I$  como  $n*k$ . Esse valor é proporcional ao tamanho da vizinhança, pois cada solução pode possuir até  $nk$  vizinhos, alterando os  $nk$  valores de  $V$ .

Para os seguintes parâmetros foram feitos testes para encontrar valores ideais experimentalmente:

- **Taxa de resfriamento** dentro do segmento  $[0.8, 0.99]$ , seguindo a implementação original de Kirkpatrick et al (1983).
- **Número de iterações** do algoritmo de Metropolis dentro do segmento  $[1, 20]$ , de forma a não elevar excessivamente o tempo de execução.
- **Temperatura mínima** dentro do segmento  $[0.1, 1000]$ .

#### Solução inicial

A solução inicial foi gerada usando um algoritmo guloso, pois permitirá encontrar soluções razoáveis com um método simples.

#### Proposta de algoritmo guloso:

1. Inicializa vetor de espaço disponível de aviões *espaçoDisponível[]* com os  $k$  pesos máximos de  $P$ . Inicializa matriz de solução  $V$  com valor 0 em todas as posições  $V_{ij}$ .
2. **Loop:**
  - 2.1. **Para** cada avião:
    - 2.2. Seleciona passageiro  $i$  com maior proporção  $c_i/p_i$ , tal que  $p_i \leq \text{espaçoDisponível}[k]$ .
      - 2.2.1. Se não houver, **termina**.
    - 2.3. Insere  $i$  em  $k$  ( $V_{ki} = 1$ ) e atualiza *espaçoDisponível*[ $k$ ] subtraindo  $p_i$  desse valor.
    - 2.4. Enquanto houver passageiro  $j$  tal que  $p_j \leq \text{espaçoDisponível}[k]$

- 2.4.1. Seleciona passageiro  $j$  com maior razão  $(c_j + c_{ji})/p_j$ .
- 2.4.2. Insere  $j$  em  $k$  ( $V_{kj} = 1$ ) e atualiza *espaçoDisponível*[ $k$ ] subtraindo  $p_j$  desse valor.

## 5. Algoritmo

**Algoritmo 1** - Algoritmo de Metropolis, recebe *solução\_atual*, *temperatura* e  $k$ .

*melhor\_solução* = *solução\_atual*

**Para** *iteração* de 0 até  $k$ :

*candidata* = *solução\_atual*

*candidata* = vizinho aleatório de *candidata*

*delta* = *candidata.valor* - *solução\_atual.valor*

**Se** *delta* > 0:

*solução\_atual* = *candidata*

**Se** *solução\_atual.valor* > *melhor\_solução.valor*:

*melhor\_solução* = *solução\_atual*

**Senão se** *delta* < 0:

*probabilidade\_de\_aceitação* =  $e^{\frac{-\text{delta}}{\text{temperatura}}}$

com probabilidade *probabilidade\_de\_aceitação* **faz**:

*solução\_atual* = *candidata*

**Retorna** *melhor\_solução*

**Algoritmo 2** - Algoritmo de Simulated Annealing

**Enquanto** (*temperatura* > *temperatura\_mínima*):

**Para** *iteração* de 0 até  $I$ :

*candidata* = **metropolis**(*solução\_atual*, *temperatura*,  $k$ )

*delta* = *candidata.valor* - *solução\_atual.valor*

**Se** *delta* > 0:

*solução\_atual* = *candidata*

*temperatura* = *temperatura* \* *resfriamento*

**Retorna** *solução\_atual*

### 5.1. Metropolis

Para o algoritmo usado na meta-heurística para busca local, foi utilizado o algoritmo de Metropolis, de forma a amostrar aleatoriamente o espaço de soluções de problema, mantendo armazenada a melhor solução, de forma a não retornar soluções piores do que a atual.

Para isso, foi implementado método que transiciona solução para um vizinho aleatório, escolhendo um valor aleatoriamente da matriz de solução e invertendo-o, caso crie solução factível. Caso não, o método seleciona outro valor aleatório até encontrar um vizinho factível.

### 5.2. Critério de terminação

Seguindo a ideia do algoritmo de simulated annealing, a implementação utilizou como condição de parada uma **temperatura mínima**. A motivação é que com o resfriamento do

recozimento, em temperaturas baixas o algoritmo aceita apenas soluções melhores, tornando-se um algoritmo de *hill climbing*, e portanto tenderá a estabilizar.

## **6. Implementação**

### **6.1. Plataforma de Implementação**

O trabalho foi testado em um sistema operacional *Arch Linux x86\_64* com um processador Intel(R) Core(TM) i3-6100 com dois núcleos físicos e 4 virtuais de 3.7GHz, com 8GB de memória. A linguagem de programação utilizada foi Python3. Para a solução dos valores ótimos foi utilizado o solver GLPK na linguagem de programação Julia através do kernel IJulia.

### **6.2. Estruturas de dados**

A matriz  $V$  foi representada na implementação através de um array bidimensional, de tamanho  $(k,n)$ .

De forma a otimizar operações de testar factibilidade, a estrutura de dados relacionada a soluções possui também um array de tamanho  $k$  que representa o peso “disponível” em cada avião. De mesmo modo, a estrutura também contém um valor inteiro representando o valor objetivo da solução, assim, soluções vizinhas não precisam ser reavaliadas, visto que a vizinhança permite que o valor objetivo seja calculado somando ou subtraindo o valor alterado.

### **6.3. Avaliação de soluções**

Dada a presença do campo de valor na estrutura de dados da solução, a avaliação de soluções consistiu em atualizar o valor da estrutura. Para isso, soluções são inicializadas com valor zero e foi implementado um método de alocação de pessoa a avião, que soma ao valor da solução o valor individual atrelado à pessoa e também os valores extras relacionados às pessoas de mesmo avião.

## **7. Teste de Parâmetros**

Três parâmetros do Simulated Annealing foram variados; a temperatura mínima, taxa de resfriamento e parâmetro  $k$  (do algoritmo metrópolis). Os valores padrões assumidos para esses parâmetros (quando não foram variados) foram, respectivamente, 10, 0.9, 10. Cada teste foi realizado 5 vezes, utilizando uma semente randômica diferente em cada uma, de modo que os valores mostrados correspondem à média dos valores obtidos nas 5 execuções.

### **7.1. Parâmetro Temperatura Mínima**

O parâmetro de temperatura mínima do Simulated Annealing foi variado, assumindo os valores  $[0.1, 1, 10, 50, 100, 200, 300, 400, 500, 600, 700, 800, 900, 1000]$ . A Figura 1 mostra os resultados.




Figura 1: Variação da temperatura mínima

Como podemos observar, a alteração do parâmetro impacta significativamente na qualidade das soluções obtidas.

### 7.2. Parâmetro Taxa de Resfriamento

A taxa de resfriamento da temperatura do algoritmo foi variada, assumindo valores entre 0.8 e 0.9, passo 0.1. Os resultados são exibidos na Figura 2.




Figura 2: Variação da taxa de resfriamento

Os resultados indicam que esse é o parâmetro que menos influencia o valor da solução encontrada. Uma possível explicação para tal é que o intervalo testado constitui uma faixa de valores condizentes para o parâmetro.

### 7.3. Parâmetro K

O parâmetro k do algoritmo Metropolis foi alterado de 1 a 20, passo 1. Os resultados são mostrados na Figura 3.




Figura 3: Variação do parâmetro k

Constata-se que a alteração do parâmetro k impacta muito significativamente na qualidade da solução em valores mais baixos, eventualmente tendendo a uma estabilização após certo crescimento.

## 8. Resultados computacionais

<i>inst</i>	<i>SI</i>	<i>SF</i>	$100*(SI-SF)/SI$	<i>desvioOtimalidade</i>	<i>tempoSA</i>	<i>tempoSolver</i>
1	104653	114099	-9,02601932	70,690412	10,8708s	22,51332s
2	104653	113923	-8,85784449	82,441373	10,8904s	22,79364s
3	104653	113828	-8,76706831	91,228007	10,6314s	23,53586s
4	327932	333694	-1,75707158	70,799139	11,6382s	22,46233s
5	327932	333732	-1,76865935	99,982515	12,0141s	22,67369s
6	327932	333547	-1,71224522	91,243600	12,2032s	22,60373s
7	417279	433669	-3,92782766	78,565360	46,5468s	22,29812s
8	417279	437535	-4,85430611	83,129684	45,6407s	23,79311s
9	417279	437916	-4,94561192	91,559425	48,4573s	24,23269s
10	1302137	1318988	-1,294103462	70,692594	51,0473s	23,15836s
11	1302137	1316608	-1,111326995	82,447286	52,1454s	23,39162s
12	1302137	1317383	-1,170844542	91,223643	52,9194s	22,36284s

Em que *inst* representa o número da instância, *SI* o valor da solução inicial encontrada pelo algoritmo guloso; *SF* o valor solução final encontrada pelo algoritmo de simulated annealing, *desvioOtimidade* o valor do desvio percentual de *SF* em relação à solução ótima encontrada via solver e *tempoSA* e *tempoSolver* o tempo de execução do algoritmo de simulated annealing e do solver, respectivamente.

## **9. Conclusões**

Os resultados obtidos indicam que a implementação do algoritmo não performou próximo à otimalidade, mas resultou em melhora do algoritmo guloso em todos os casos. A nossa configuração proposta para a execução do algoritmo é:  $T_{min} = 1$ ,  $cooling\_rate = 0.87$ ,  $k = 10$ .